

Attention Residuals (AttnRes)


[MoonshotAI/Attention-Residuals](#)

[【闪客】深入解读 Kimi 爆火论文，马斯克都转了！到底什么是注意力残差？白话解读哟_哔哩哔哩_bilibili](#)


梯度

梯度随着神经网络的层数加深，以连乘的形式累积

梯度消失




梯度爆炸



梯度消失和梯度爆炸会影响神经网络训练稳定性

Residual Connection





残差: $F(a_0) = a_1 - a_0$

网络只需要学习输入与输出之间的差异（残差），而不是学习整个映射

| HC 和 mHC

前情提要:


 (HC)  (mHC)




- **ResNet**: 信息越走越弱，深层记不住浅层，数值会爆炸。
- **HC**: 门控太弱，学不出有效权重，还是会稀释。
 - 拓宽通道数，信息传递时乘以一个可学习的矩阵
- **mHC**: 只解决数值稳定，不解决信息遗忘。
 - 对 HC 中的可学习矩阵加上流形约束

» 总结：这三种方法都是将残差流从左到右一层层传递（效率有限）


AttnRes



(a) Standard Residuals



(b) Full Attention Residuals



(c) Block Attention Residuals

AttnRes借鉴Transformer的注意力机制，选择性地加权，聚合所有前一层的输出。为了缓解层数太多导致的注意力计算消耗过大，采用分块思想（和QKV分组有异曲同工之妙）。